

Trabalho 1 — Atividade Integradora

Ficha de Respostas (individual, em sala)

Instruções — leia antes de começar

Atividade SEM consulta à internet.

Preencha o PRONTUARIO no script trabalho1_integrador.py exatamente como está na sua matrícula, rode o script e transcreva os números pedidos abaixo.

Todas as justificativas devem citar os números que APARECERAM NA SUA TELA — respostas genéricas, sem os seus números, não pontuam.

Vale 1,5 ponto no total: Parte 1 = 0,5 • Parte 2 = 0,35 • Parte 3 = 0,2 • Parte 4 = 0,45.

Nome: Léo Martelli

Prontuário: PE3021742 Semente pessoal (impressa na tela): 21742

Parte 1 — Supervisionado: k-NN e padronização (0,5)

Pergunta 1 (0,3) — Os 3 solicitantes mais próximos do candidato (distância padronizada), na ordem, com a distância de cada um:

S7	2825.9	3.714	0
S8	4152.4	4.995	1
S5	4551.6	5.083	0

Quantos desses 3 são "aprovado = 1" e quantos são "aprovado = 0"? (votação)

Votação: 2 não-aprovado, 1 aprovado

Classificação final dada ao candidato (marque um):

() Aprovado (X) Não aprovado

Justifique com base nas distâncias (por que esses 3 e não outros?):

Baseado nos 3 mais próximos, contabilizei a maioria (não aprovado) e verifiquei que ele não foi aprovado.

Pergunta 2 (0,2) — Sem padronizar, o solicitante mais próximo do candidato era: S7. Padronizando, passou a ser: S7 (mesmo, se não mudou).

Sem padronizar: S7 Padronizado: S7

Qual atributo é o principal responsável pela diferença, e por que padronizamos antes de calcular distância no k-NN?

O atributo principal que influência na diferença é a renda. Uma vez que ele está na casa dos milhares, e o restante está na casa das centenas e dezenas.

Parte 2 — Não supervisionado: agrupamento por similaridade (0,35)

Grupo A = { S1, S5, S6, S8 }

Grupo B = { S2, S3, S4, S7 }

Justifique citando pelo menos 2 distâncias da matriz (por que esses dois grupos?):

No Grupo A, S1-S8 = 1,51, S5-S8 = 1,60 e S5-S6 = 1,68

No Grupo B, S2-S4 = 1,29, S3-S4 = 2,23 e S2-S3 = 2,40.

Parte 3 — Preparação de dados e tipos de atributo (0,2)

Classifique CIDADE quanto ao tipo (nominal, ordinal, intervalar ou racional) e justifique:

Cidade é nominal.

É um atributo sem ordem entre os valores, não tem como categorizar uma cidade e dizer se uma é “maior” ou “menor” que outra.

Classifique SCORE_CREDITO quanto ao tipo (nominal, ordinal, intervalar ou racional) e justifique:

Score_credito é racional.

É numérico e possui zero absoluto. Além disso, diferenças e razões entre valores podem ser interpretadas quantitativamente.

Parte 4 — Regressão: previsão e resíduo na mão (0,45)

Pergunta 5 (0,25) —

$b_0 = 29,75$ $b_1 = 17,75$

Cálculo manual de y_{previsto} (mostre a conta):

$Y_{\text{previsto}} = 29,75 + 17,50 * \text{area_m2}$

$y_{\text{previsto}} = 29,75 + 17,50 * 68,9$

$y_{\text{previsto}} = 29,75 + 1205,75$

$y_{\text{previsto}} = 1235,50$

Cálculo do resíduo ($y_{\text{real}} - y_{\text{previsto}}$):

$Y_{\text{real}} = 927,72$

$\text{resíduo} = y_{\text{real}} - y_{\text{previsto}}$

$\text{resíduo} = 927,72 - 1235,50$

$\text{resíduo} = -307,78$

Pergunta 6 (0,2) —

Seu $R^2 = 0.7599$ Aproximadamente % explicado = 76%

Compare com o $R^2 = 0,7707$ da demonstração da Aula 7.1. O fato do seu número ser diferente significa que a regressão “não funciona direito”, ou é esperado por usar um recorte diferente dos mesmos dados? Justifique:

O meu R^2 é menor que o da demonstração.

Isso é esperado, pois utilizei um recorte diferente dos mesmos dados, então o R^2 pode variar um pouco, pois como cada aluno coloca sua “semente”, o resultado adquire uma porção diferente dos mesmos dados.
